先端機械学習　後半課題

提出日：2021 年 8 月 10 日

情報工学系

学籍番号：18B14822

氏名：宮崎　直哉

1　問題 1

パラメータ b の値：

$$b = (0, -1000, -1000, -2000, -2000, -3000)$$

パラメータ b を求める方法：

本問題では $w_i = 1000 (i = 1, 2, 3, 4, 5, 6)$ である。この時、シグモイド関数は下図のようになる。この時、このシグモイド関数はステップ関数と考えることができる。

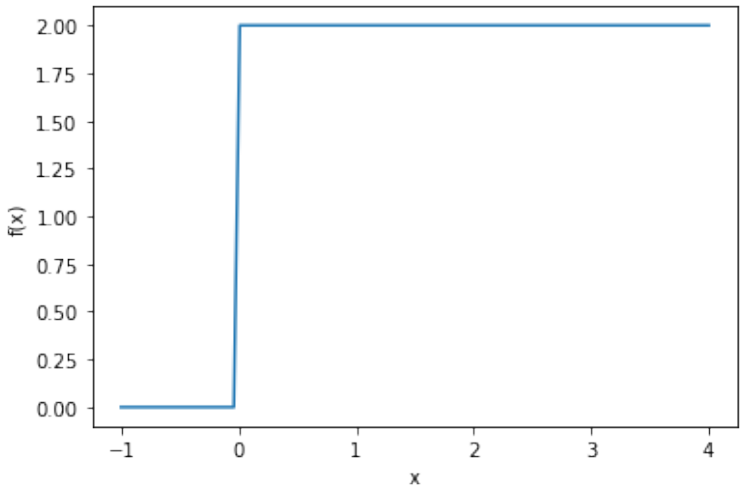

この時、$g_i = v_i\sigma(1000x + b_i)$ という式の意味を考えてみる。すると、シグモイド関数は x から [0,1] 区間への写像であるので、v_i はステップ関数の高さを表すことがわかる。また、

$$\begin{aligned} g_i &= v_i\sigma(1000x + b_i) \\ &= v_i\sigma\left(1000(x + \frac{b_i}{1000})\right)) \end{aligned}$$

と変形すると、$x = -\frac{b_i}{1000}$ がステップ関数の変換点となっていることがわかる。例えば、

$$f(x) = \begin{cases} 0 & (x < 3) \\ 5 & (3 \leq x) \end{cases}$$

となるようなステップ関数をシグモイド関数で近似することを考えると、変換点が $x = -\frac{b_i}{1000} = 3$ で高さ $v_i = 5$ で あるので、

$$g = 5\sigma(1000x - 3000)$$

とすれば、下図のようにステップ関数をシグモイド関数で近似したグラフを意図して得られる。

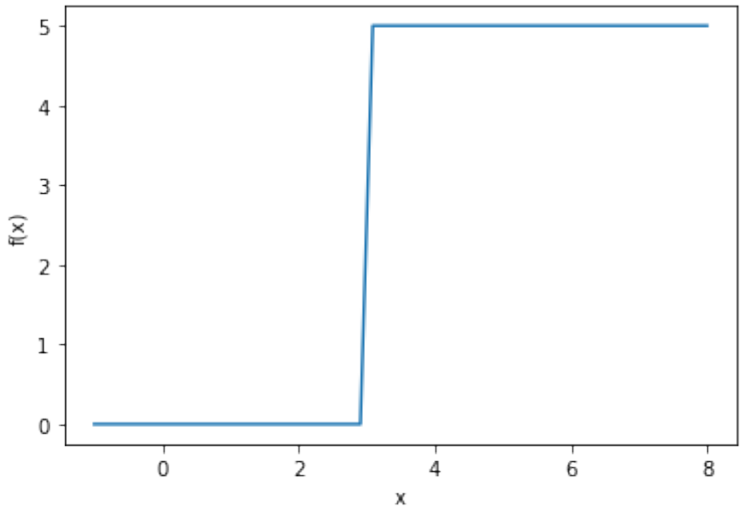

この性質を利用して本問題を考えてみる。$f(x)$ は以下のグラフのようである。

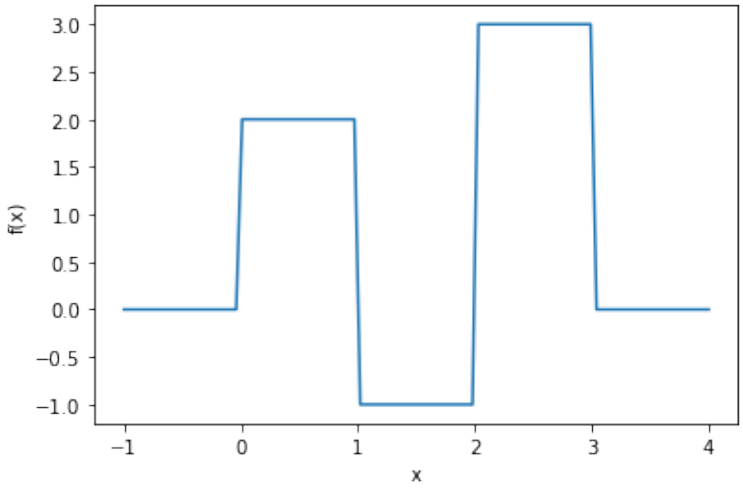

式 $g(x)$ はシグモイド関数の和で表現されているので、上記の性質を合成した関数 g を作成することができる。ここで考えることは、ステップ関数の変換点と高さである。変換点として考えるべきなのは $x = 0, 1, 2, 3$ である。高さの変化については、$x = 0 : +2$、$x = 1 : -3$、$x = 2 : +4$、$x = 3 : -3$ となっている。高さについては、パラメータ v の値を見ていくと、$x = 0$ において高さ $v_0 = 2$,$x = 1$ において高さ $v_1 = -2, v_2 = -1$,$x = 2$ において高さ $v_2 = 1, v_3 = 3$,$x = 3$ において高さ $v_6 = -3$ のステップ関数をそれぞれ適用することで、$||f(x) - g(x)|| < \epsilon$ となるようなパラメータ b を決定することができる。

(本問題で作成したソースコードは`https://github.com/naoyaaan/AdvancedMachineLearning/blob/main/Okazaki/final.ipynb` にアップロードしています。)

2　問題 2

(1)

$$h = \begin{pmatrix} 0 \\ 1.5 \end{pmatrix}$$

$$\hat{y} = 0.5$$

(2)

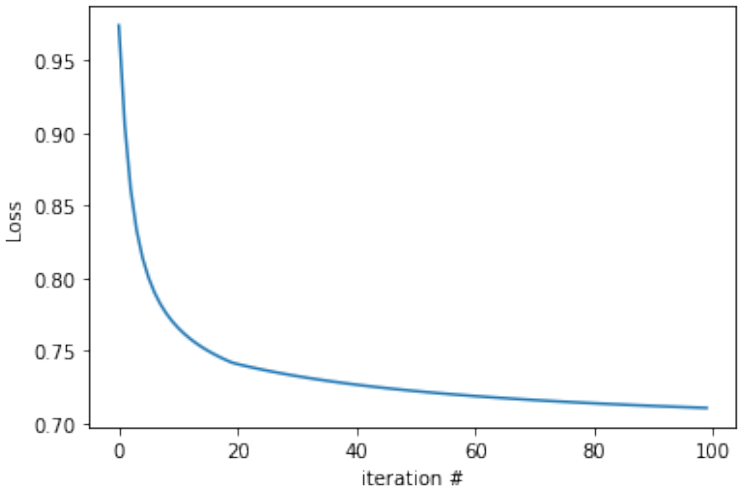


```
w:
Parameter containing:
tensor([[ 0.4912,  0.4912],
        [-1.0000, -1.0000]], requires_grad=True)
q:
Parameter containing:
tensor([[0.4744],
        [1.0000]], requires_grad=True)
b:
Parameter containing:
tensor([[-1.0088],
        [ 1.5000]], requires_grad=True)
c:
Parameter containing:
tensor([[-3.3401]], requires_grad=True)
Text(0, 0.5, 'Loss')
```

(本問題で作成したソースコードは`https://github.com/naoyaaan/AdvancedMachineLearning/blob/main/Okazaki/final.ipynb` にアップロードしています。)

3 問題 3

3.1 WordSim-353

評価に用いられるタスクの概要

WordSim-353(WS353) は単語の類似性または関連性を測るためのデータセットである。Word Similarity Task(単語の類似性を測るタスク) では、モデルによる単語間の類似性の評価と人間による評価の相関を計測する。

データセットの統計情報

データセットの統計情報は以下の表のようである。

	pairs	**type**	**raters**	**scale**	**Complex words**	
					token	type
WS353	353	437	13-16	0-10	24	17
MC	30	39	38	0-4	0	0
RG	65	48	51	0-4	0	0
SCWS*	1762	1703	10	0-10	190	113
RW (new)	2034	2951	10	0-10	987	686

pairs は類似性を測る二つの単語を、raters は評価した人間の人数,scale は類似性のスコアを表している。

評価の尺度

上記のタスクによる評価には Spearman ' s rank correlation coefficient の値 ($\rho \times$ 100) が用いられる。ρ は [-1,1] の値をとり、この値が大きいほど、人間の評価とモデルの評価に相関があることを表している。以下の表は実際にこのデータセットを用いてモデルを評価したときの結果である。

		sg	cbow	sisg-	sisg
AR	WS353	51	52	54	**55**
DE	GUR350	61	62	64	**70**
	GUR65	78	78	**81**	**81**
	ZG222	35	38	41	**44**
EN	RW	43	43	46	**47**
	WS353	72	**73**	71	71
ES	WS353	57	58	58	**59**
FR	RG65	70	69	**75**	**75**
RO	WS353	48	52	51	**54**
RU	HJ	59	60	60	**66**

3.2 IMDb

評価に用いられるタスクの概要

IMDb はテキスト分類のタスクを評価するために用いられる。具体的には、Sentiment Analysis, Topic Detection, Language Detection などのタスクがある。Sentiment Analysis は、 テキストがポジティブかネガティブがどちらでもないかを測るタスクである。Topic Detection は、自動的にそのテキスト、文章のテーマ、トピックを特定するタスクである。Language Detection は、与えられたテキストの言語を決定するタスクである。

データセットの統計情報

IMDb は the Internete Movie Database というサイトにおける、ポジティブ、ネガティブをラベル付けされた 50000 件のレビューからなるデータセットである。ポジティブとネガティブのレビューが同じ数だけ収録されている。10 段階の評価で 4 以下がネガティブ、7 以上がポジティブと判断している。

評価の尺度

IMDb を用いた Sentiment Analysis では、モデルのポジティブ or ネガティブの正答率 (%) を用いて評価している。以下の表は、現在の IMDb におけるモデルの予測精度のランキングである。

Model	Accuracy	Paper / Source
XLNet (Yang et al., 2019)	96.21	XLNet: Generalized Autoregressive Pretraining for Language Understanding
BERT_large+ITPT (Sun et al., 2019)	95.79	How to Fine-Tune BERT for Text Classification?
BERT_base+ITPT (Sun et al., 2019)	95.63	How to Fine-Tune BERT for Text Classification?
ULMFiT (Howard and Ruder, 2018)	95.4	Universal Language Model Fine-tuning for Text Classification
Block-sparse LSTM (Gray et al., 2017)	94.99	GPU Kernels for Block-Sparse Weights
oh-LSTM (Johnson and Zhang, 2016)	94.1	Supervised and Semi-Supervised Text Categorization using LSTM for Region Embeddings
Virtual adversarial training (Miyato et al., 2016)	94.1	Adversarial Training Methods for Semi-Supervised Text Classification
BCN+Char+CoVe (McCann et al., 2017)	91.8	Learned in Translation: Contextualized Word Vectors

4　問題 4

系列変換タスクにおいて、Transformer が再帰型ニューラルネットワーク (RNN) よりも優れている点として以下の 2 つが挙げられる。

1. 計算時間が早い
2. 並列化が可能

まず Transformer では下図のような構造を用いている。

この中でも Transformer においては Self-Attention をベースとした構造となっている。RNN をベースとした構造と比較したのが下表である。

これによると、RNN のレイヤーでは、$O(n^2 \cdot d)$ の計算量となっているが、Self-Attention では $O(n \cdot d^2)$ となっている。これだけでは RNN が Transfomer より計算量が早いことはわからない。しかし、n(sequence length) や d(representation dimension) のサイズに注目してみると、たいていの場合 $n < d$ と n よりも d のほうがはるかに大きくなっている。そのため、Self-Attention のレイヤーのほうが計算量が少ないことがわかる。

また、RNN では入力に対してステップを経て処理をするので、Maximium path length の計算量は $O(n)$ であるのに対して、Self-Attention は並列計算を行うので、Maximium path length の計算量は $O(1)$ となっている。GPU 演算を行うことを考えると Self-Attention は並列化できることというのが計算量の削減につなっており、RNN の構造よりも優れた点であるといえる。

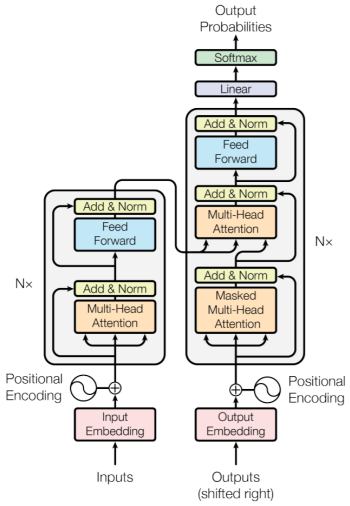

Figure 1: The Transformer - model architecture.

Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the representation dimension, k is the kernel size of convolutions and r the size of the neighborhood in restricted self-attention.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(log_k(n))$
Self-Attention (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

5 問題 5

参考文献

[1] Piotr Bojanowski, Edouard Grave, Armand Joulin, Tomas Mikolov. Enriching Word Vectors with Subword Information. arXiv:1607.04606. 2017

[2] Minh-Thang, Luong Richard Socher, Christopher D. Manning. Better Word Representations with Recursive Neural Networks for Morphology.

[3] NLP-progress. `http://nlpprogress.com/english/sentiment_analysis.html`. 閲覧日：2021 年 8 月 3 日

[4] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin. Attention Is All You Need. arXiv:1706.03762. 2017

[5]

[6]

[7]

[8]

[9]

[10]

[11]